Universidad de Guadalajara

Centro Universitario de los Valles

Ingeniería en Electrónica y Computación

Shannon

Compresor de Rango Dinámico con
Predicción Automática de Parámetros

Autores: Paul Emanuel Contreras Covarrubias
Alexis Moises Torres Martínez
Angel Rafel Oliva Ramírez

Correo: paul.contreras6403@alumnos.udg.mx

Profesor: Dra. Teresa Efigenia Alarcón Martínez
Materia: Análisis de Señales y Sistemas — 187670

23 de marzo de 2026

Índice

1. Introducción **3**

2. Objetivo **4**

Resumen

El control del rango dinámico es una etapa crítica en la producción de audio digital: sin él, las diferencias de volumen entre las partes más silenciosas y más intensas de una grabación pueden superar los 60 dB, nivel inaceptable para plataformas de distribución como Spotify o Apple Podcasts, que operan bajo el estándar EBU R128 [6].

Las herramientas actuales enfrentan una dicotomía irresuelta: los servicios en la nube automatizan el proceso pero lo tratan como una caja negra, sin exponer ninguna justificación al usuario; las estaciones de trabajo de audio digital (DAW) profesionales ofrecen control total pero exigen una curva de aprendizaje elevada y costos de licencia prohibitivos para productores independientes y estudiantes. El espacio entre ambos extremos (herramientas accesibles con razonamiento transparente) permanece desatendido en el ecosistema de productos disponibles.

Este trabajo propone **Shannon**, un compresor de rango dinámico nativo que integra un motor DSP de alto rendimiento con un *Auto Mode* capaz de razonar explícitamente sobre las características de la señal de entrada. El *Auto Mode* combina un modelo de lenguaje de gran escala (LLM) que genera, en lenguaje natural, una traza de razonamiento auditable sobre las decisiones de compresión, con un modelo de regresión ligero ejecutado localmente que refina numéricamente los parámetros propuestos. La contribución central del trabajo es la exposición de dicha traza de razonamiento como artefacto estructurado, inspeccionable y corregible por el usuario, extendiendo el modelo de inteligencia artificial explicable (XAI) al dominio del procesamiento dinámico de audio.

1. Introducción

La dinámica de una señal de audio (la relación entre sus niveles más silenciosos y más intensos) es uno de los parámetros perceptuales más relevantes en la producción sonora moderna. En grabaciones musicales, podcasts y contenido multimedia, el rango dinámico puede superar los 60 dB, un margen que los sistemas de reproducción domésticos y los estándares de distribución en plataformas digitales no están diseñados para absorber sin distorsión o pérdida de inteligibilidad. El compresor de rango dinámico (*Dynamic Range Compressor*, DRC) es el procesador de señal encargado de reducir dicha variación de forma controlada, preservando la naturalidad del contenido sonoro mientras garantiza su conformidad con los niveles de referencia exigidos por plataformas como Apple Podcasts, Spotify y YouTube, las cuales adoptan el estándar EBU R128 [6] con objetivos de intensidad integrada entre -23 y -14 LUFS.

Sin embargo, el acceso a estas herramientas enfrenta una brecha significativa: los productores independientes y creadores de contenido deben elegir entre servicios en la nube que automatizan la compresión como una caja negra (sin retroalimentación visible ni justificación de las decisiones aplicadas) y estaciones de trabajo de audio digital (DAW) profesionales que exponen el proceso completo pero imponen curvas de aprendizaje elevadas y costos de licencia prohibitivos. Esta brecha entre accesibilidad y transparencia permanece desatendida tanto en la literatura académica como en el ecosistema de productos disponibles, y constituye la motivación central del presente trabajo.

Desde la formalización matemática del DRC digital propuesta por Giannoulis, Massberg y Reiss [1], el diseño de estos sistemas ha evolucionado de manera significativa. La caracterización precisa de las constantes de tiempo de ataque y relajación [2] permitió modelar con exactitud el comportamiento transitorio de los compresores analógicos clásicos. Más recientemente, la emergencia del aprendizaje automático abrió una línea de investigación orientada a la predicción automática de parámetros: Ramos-Vidal et al. [3] propusieron un modelo de regresión que estima los parámetros óptimos de compresión a partir de las características de un audio de referencia, mientras que SignalTrain [4] extendió este enfoque mediante redes neuronales profundas capaces de emular el comportamiento dinámico completo de compresores analógicos.

No obstante, estos enfoques comparten una limitación fundamental: tratan la predicción de parámetros como un problema de regresión pura, omitiendo la dimensión semántica del razonamiento que un ingeniero de audio experto aplica al configurar un compresor. Un ingeniero experimentado no solo ajusta números: analiza el contenido, infiere la intención del material sonoro y justifica cada decisión en función del contexto de producción. Ningún modelo de regresión existente captura ni expone ese razonamiento al usuario. La incorporación de modelos de lenguaje de gran escala con capacidad de cadena de pensamiento (*chain-of-thought*) abre la posibilidad de cerrar precisamente esta brecha.

En este trabajo se propone **Shannon**[1], un compresor de rango dinámico nativo que aborda esta brecha mediante la integración de un motor DSP transparente con un *Auto Mode* basado en razonamiento generado por un LLM. Las contribuciones principales del presente trabajo son las siguientes:

[1] El nombre rinde homenaje a Claude E. Shannon, padre de la teoría matemática de la comunicación [5], cuyo trabajo sobre información y entropía es fundamento de las telecomunicaciones y el procesamiento digital de señales.

1. Un motor DSP de arquitectura *feedforward* con detección de nivel RMS, filtro de balísticas, computador de ganancia con curva de rodilla suave (*soft-knee*), buffer de anticipación (*lookahead*), ganancia de compensación y medición de intensidad sonora conforme al estándar EBU R128.
2. Un *Auto Mode* en dos etapas: un LLM con capacidad de *chain-of-thought* analiza las características espectrales y dinámicas de la señal y produce simultáneamente una traza de razonamiento estructurada y legible, y una propuesta inicial de parámetros de compresión; dicha propuesta es refinada por un modelo de regresión ligero ejecutado localmente.
3. La exposición del *chain-of-thought* del LLM como artefacto estructurado, inspeccionable y corregible por el usuario, extendiendo el modelo de inteligencia artificial explicable (XAI) al dominio del procesamiento dinámico de audio.

Para verificar la viabilidad de estas contribuciones se diseñaron tres experimentos, cada uno orientado a validar un componente independiente del sistema:

1. **Validación del motor DSP:** medición de la reducción de ganancia frente a valores teóricos para distintos tipos de señal de audio.
2. **Evaluación del *Auto Mode* con LLM:** comparación de los parámetros generados por el LLM con configuraciones establecidas por referencia experta.
3. **Evaluación del *pipeline* completo** (experimento de mayor relevancia del presente trabajo): cuantificación de la mejora que aporta el modelo de regresión sobre los parámetros propuestos por el LLM en solitario.

2. Objetivo

Objetivo general

Diseñar y proponer la arquitectura de **Shannon**, un compresor de rango dinámico nativo que integra un motor DSP de alto rendimiento con un *Auto Mode* basado en razonamiento explícito mediante modelos de lenguaje de gran escala, demostrando que la incorporación del *chain-of-thought* como artefacto auditable extiende el modelo de IA explicable (XAI) al dominio del procesamiento dinámico de audio.

Objetivos específicos

1. Implementar y validar un motor DSP *feedforward* que reduzca el rango dinámico de señales de audio de acuerdo con valores teóricos de referencia.
2. Evaluar la capacidad del LLM para proponer parámetros de compresión coherentes con configuraciones establecidas por referencia experta.
3. Cuantificar la mejora que aporta el modelo de regresión local sobre la propuesta inicial del LLM en el *pipeline* completo de dos etapas.

Referencias

[1] D. Giannoulis, M. Massberg y J. D. Reiss, "Digital dynamic range compressor design — a tutorial and analysis," *Journal of the Audio Engineering Society*, vol. 60, no. 6, pp. 399–408, 2012. Disponible en: https://www.eecs.qmul.ac.uk/~josh/documents/2012/GiannoulisMassbergReiss-dynamicrangecompression-JAES2012.pdf

[2] F. Floru, "Attack and release time constants in RMS-based feedback compressors," *Journal of the Audio Engineering Society*, vol. 47, no. 10, pp. 788–804, 1999. Disponible en: https://www.thatcorp.com/datashts/AES4703_Attack_and_Release_Time_Constants_I.pdf

[3] J. Ramos-Vidal, J. Janer y X. Serra, "Automatic control of the dynamic range compressor using a regression model and a reference sound," en *Proc. 20th Int. Conf. Digital Audio Effects (DAFx-17)*, Edinburgh, UK, 2017, pp. 1–7. Disponible en: https://dafx17.eca.ed.ac.uk/papers/DAFx17_paper_44.pdf

[4] J. C. Comunità, C. Steinmetz y J. D. Reiss, "SignalTrain: Profiling audio compressors with deep neural networks," en *Proc. IEEE Int. Conf. Acoustics, Speech and Signal Processing (ICASSP)*, Brighton, UK, 2019. Disponible en: https://arxiv.org/abs/1905.11928

[5] C. E. Shannon, "A mathematical theory of communication," *Bell System Technical Journal*, vol. 27, no. 3, pp. 379–423, 1948. Disponible en: https://people.math.harvard.edu/~ctm/home/text/others/shannon/entropy/entropy.pdf

[6] European Broadcasting Union, *EBU R 128 — Loudness Normalisation and Permitted Maximum Level of Audio Signals*, EBU, Geneva, 2020. Disponible en: https://tech.ebu.ch/docs/r/r128.pdf